

Task 2-1

一、SAM和深度估计

1.什么是SAM(Segment Anything)?

SAM是能够把一张图片中的所有物体的边缘完美、丝滑地扣出来的技术，具有极强的识别轮廓能力。

核心原理：

- **图像编码器 (Image Encoder):** 基于 ViT-H (Vision Transformer Huge)，负责对图像进行深度特征提取。这是最耗时的部分，但一张图只需要运行一次。
- **提示编码器 (Prompt Encoder):** 将用户的点击（点）、框选（Box）或语言描述转化为向量。
- **掩码解码器 (Mask Decoder):** 极其轻量级。结合图像特征和提示特征，**毫秒级**生成分割掩码。这就是为什么上面的交互式 Demo 可以做到实时响应

2.什么是Depth(单目深度估计)

能够通过把图像变为热力图来判断物体的距离

💡 反直觉现象

越亮的地方离得越近，越黑的地方离得越远

原理：

使用DPT(Dense Prediction Transformer)

- **遮挡关系:** 物体A挡住物体B，A更近。
- **透视关系:** 道路远端汇聚成一点。
- **相对大小:** 同样是车，看着小的离得远。

3.强强联合

SAM识别物体+Depth识别距离

二、评测指标

1.分割质量(Segmentation Quality):

mIoU(mean Intersection over Union): SAM通常能达到**90%+** 的 IoU，意味着它扣出的物体边缘极度贴合真实物体

(1)IoU(交并比 Intersection over Union)

人工标准答案(Ground Truth): 就像老师用剪刀极其完美地剪出来的水杯轮廓 (面积设为 A)

AI的答案(Prediction): AI 抠出来的水杯轮廓 (面积设为 B)

- **交集 (Intersection) :** 它们俩完美重合的部分
- **并集 (Union) :** 它们俩总共盖住的桌子面积 (也就是 A 和 B 加起来, 减去重合部分)

👉 计算公式: $\text{IoU} = \text{交集面积} \div \text{并集面积}$

- **如果 AI 完美命中了标准答案:** 两张纸完全重合, 交集等于并集, $\text{IoU} = 1$ (也就是 100%)
- **为什么用这个公式? 防止 AI 作弊!** 如果 AI 直接耍赖, 把**整张图片**都涂成红色, 说“水杯在里面”。此时“交集”虽然包含了整个水杯, 但“并集”是整张图片。这一除, IoU 可能只有 5%, AI 就露馅了

✍️ 我自己的理解

也就是交集越大越好, 并集越小越好, 两者相互制衡

(2)mIoU:

前面的 m 代表 **mean (平均)**

测试有1000个样本包含了抠猫、抠狗、抠车等 1000 个物体。把这 1000 个物体的 IoU 分数加起来除以 1000, 就是 mIoU

2.深度准确性(Depth Accuarcy):

RMSE (均方根误差Root Mean Square Error): 衡量预测深度与真实深度的偏差

AbsRel (绝对相对误差Absolute Relative Error): 越低越好

💡 Tip

单目深度估计通常输出**相对深度 (Relative Depth)** (如 0~1 的值)，在实际应用中，通常需要通过相机参数或一个已知参考点将其对齐到真实世界尺度 (米)

RMSE:

算误差：AI 猜水杯离我 2 米，实际是 3 米。误差是 $(2 - 3) = -1$ 米。

求平方 (核心机制)：把误差平方 $(-1)^2 = 1$

为什么要平方？第一，消灭负数，负的误差也是误差；第二，暴击严惩离谱的错误！如果误差是 0.1 米，平方后是 0.01 (原谅你)；如果误差是 10 米，平方后是 100 (让你总分瞬间爆炸)

算平均 (Mean)：把画面里所有 100 万个像素的“误差平方”加起来，除以 100 万，算出一个平均值

开根号 (Root)：因为刚才平方了，单位变成了“平方米”，为了把单位还原回“米”，最后给总分开个根号

AbsRel:

有了RMSE，还要有AbsRel的原因是因为同样的误差，在不同距离下，严重程度完全不同！

💡 Tip

- **场景 A**：机器人要抓水杯。实际 1 米，AI 猜 2 米。（误差 1 米）—— 致命错误，机械臂直接把桌子捅穿了！
- **场景 B**：自动驾驶看前方的山。实际 100 米，AI 猜 101 米。（误差也是 1 米）—— 毛毛雨，完全不影响开车。

如果只看误差的绝对值，场景 A 和场景 B 分数一样，这显然不合理。所以我们需要算“相对比例”。

公式： $|\text{AI猜的距离} - \text{真实距离}| \div \text{真实距离}$

- 场景 A： $|2 - 1| \div 1 = 100\%$ 的误差。（严厉扣分）
- 场景 B： $|101 - 100| \div 100 = 1\%$ 的误差（表现优秀）

📌 Note

AbsRel也是越小越好。与mIoU之间的差别在于AbsRel是使用百分比衡量误差而不是绝对长度

三、相对深度 vs 绝对尺寸

为什么单张照片猜不出绝对的“米”？

假设我给你看一张照片，里面有一辆车。

- 这可能是一辆**真实的汽车**，停在 **50 米**外。
- 这也可能是一个**玩具小汽车**，放在镜头前 **0.5 米**的地方。
在单张 2D 照片上，这两种情况的画面是**一模一样的**（这就是电影特效经常用的强迫透视）。神仙也看不出绝对的距离。

所以 AI 输出的是什么？

单目 AI 输出的是一张 **0 到 1 的“相对灰度图”**（0 是最黑，1 是最白）。

它只知道：“这个水杯比后面的墙亮，所以水杯离镜头更近。”至于近多少米？它不知道。

怎么解决这个死穴？（对齐到真实世界）

机器人如果只拿着 0~1 的图是没法走路的。必须给它一个参考答案

利用相机参数（焦距等物理参数）： 如果知道相机的内参，可以通过几何推导把像素反算回真实大小。

给一个基准点： 比如机器人身上装了一个极其精准的**激光测距仪**（只测一个点）。

激光告诉 AI：画面正中心那个点，距离是确切的 2.5 米。AI 就恍然大悟，把那张 0~1 的图，按比例膨胀成真正的距离表